



Place de marché

Objectif: étudier la faisabilité d'un moteur de classification

Nota Bene : faisabilité de regrouper automatiquement des produits de même catégorie => **clustering**





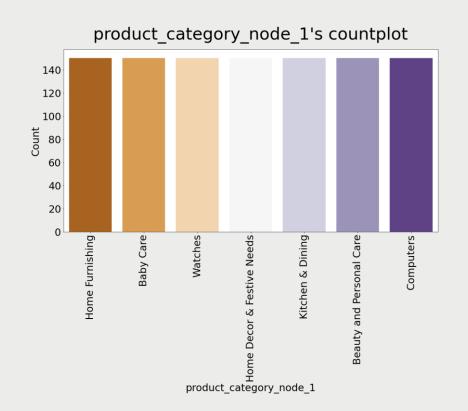


Dataframe

1050 produits indiens

Données tabulaires + données non tabulaires (Texte & Image)

Labels en nœuds





Catégories Nœud 1















Home Furnishing

Baby Care

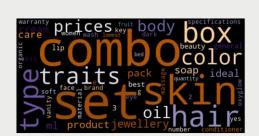
Watches



Catégories Nœud 1













Home Decor & Festive Needs

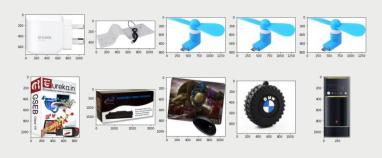
Kitchen & Dining

Beauty and Personal Care



Catégories Nœud 1





Computers



श्रीगणिन्यायनमः॥ ७०३ मः॥ ज्यानितं। र्कि। युरः रहितं। यसस्य। रेवं। आतितं ॥होतारं।रल्उधार्तमं॥छ्यग्निः।पूर्वभिः। नर्षिऽभिः। रहमः। स्त्निः। उत्। सः। देवा न्।जा। इर्। वस्ति। ज्यमिना।र्थि। जनमन्त्र पोर्ष। एव। दिवे दिवे । वस्ति। वीरवंत्र्वतमंगअन्त्यंभ्युर्तभ्यव्यरं विश्वतं अपूर्विन्यतं अपूर्वे अपूर्व Natural Language Processing रः॥उपात्वा अग्ने। द्वेऽदिग दीषातुरतः। धिया। वयं ॥नमः। भरतः। आ। र्मासा राजंत्र अध्वराणां भागापा अतस्य दिदिवं भवर्षमानं स्व इने । सः नः पिताः र्वा सन्ये अने मुख्यायनः भ्वासर्वस्ति । स्त्रस्तये ॥ २॥ गायाद्वि आ । याक्ष

Prétraitement du texte

Tokenization
Casse
Stop Words
Mots Rares et Trop Fréquents
Ponctuation
Part of Speech
(Out of Vocabulary)
Lemmatisation

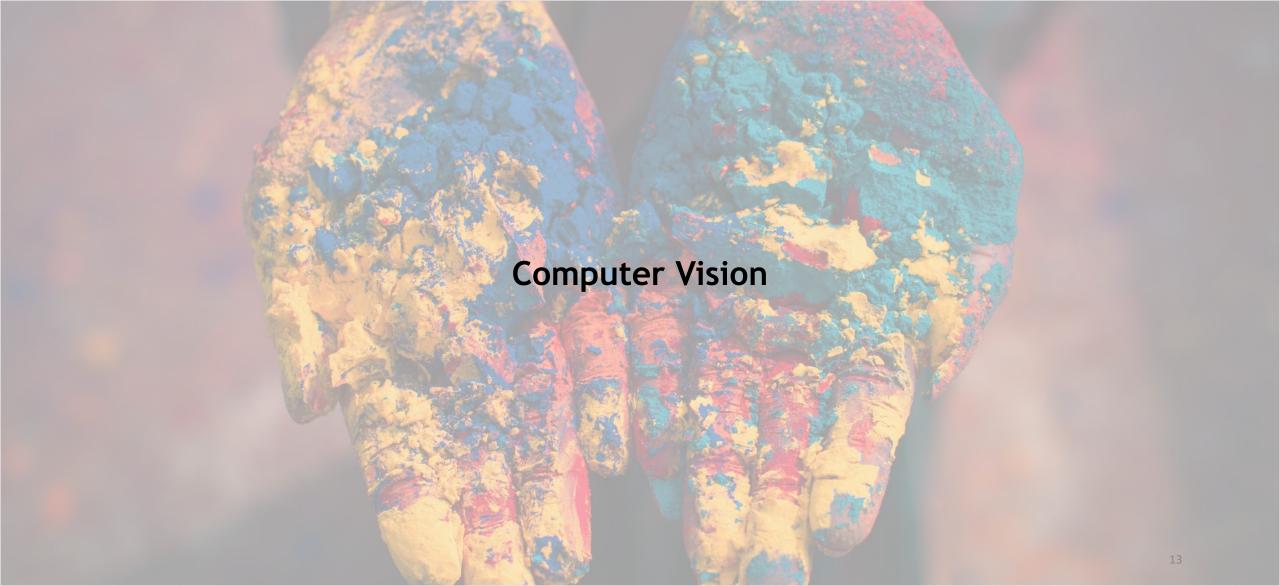
Extraction des features

Bag of words: Compte, TF-IDF (1050, 3249)

Modèles Préentrainés:

1. Sans contextes:
Word2VEC, Glove, FastText, spacy's
(1050, 300)

2. Avec contextes: BERT (1050, 768) USE (1050, 512)





Extraction des features

Bag of Visual Words:

SIFT (1050, 719) ORB (1050, 721) SIFT 500 first keypoints on a watch



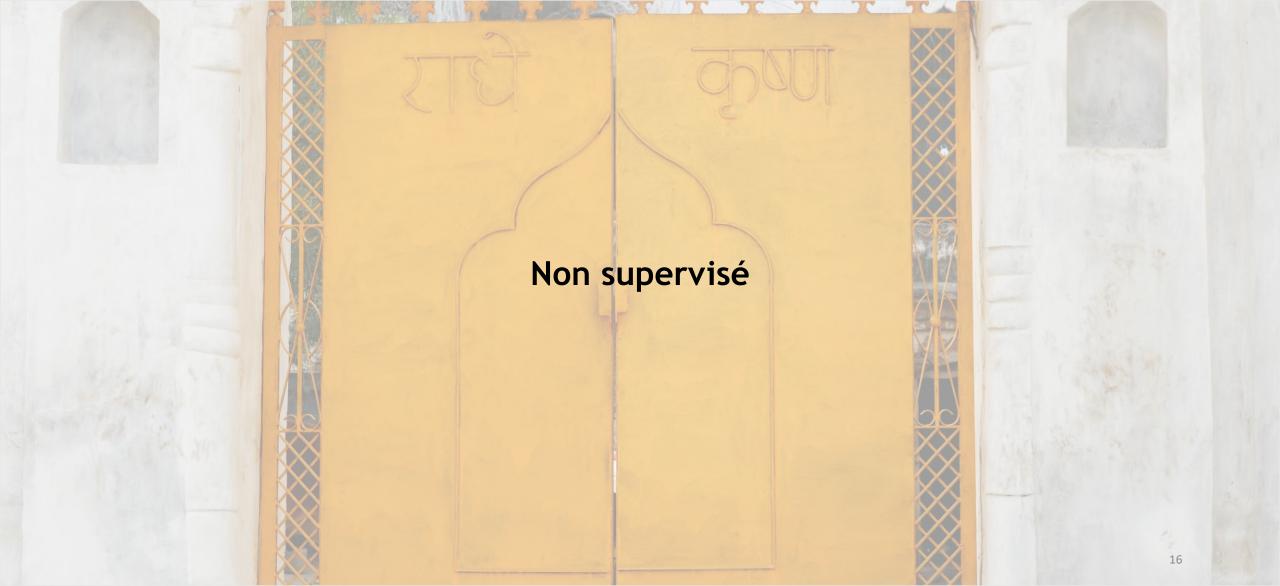
ORB 500 first keypoints on a watch



Convolution neural NN (Flatten Layer):

VGG-16 (1050, 25088) ResNet50V2 (1050, 100352) EfficientNetB0 (1050, 62720)







Modélisation et Dimensionnalité

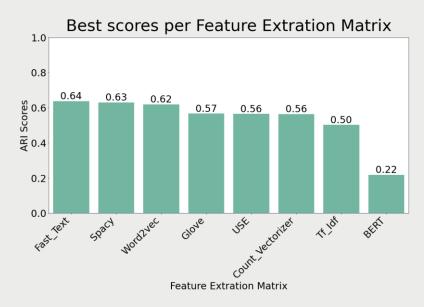
Modélisation:

KMEANS 7 Composants

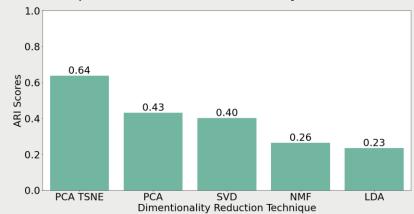
Réduction de dimensionnalité :

PCA (% de variance)
PCA puis TSNE
Latent Dirichet Allocation
Singular Value Decomposition
Non negative Matrix Factorization

Catégorie: premier nœud (7 catégories) NLP

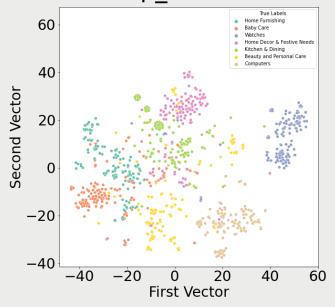


Best scores per Feature Dimentionality Reduction Technique

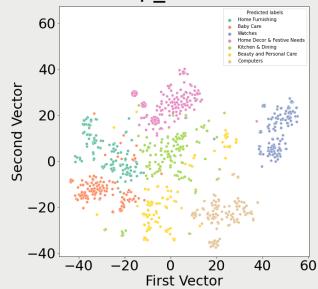


Catégorie: premier nœud (7 catégories) - Spacy's Embedding - ARI: 0,64

PCA t-SNE nlp_matrix True Labels



PCA t-SNE nlp_matrix Predictions



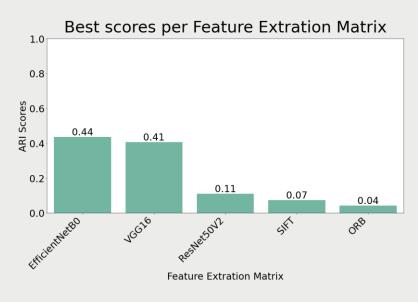
Catégorie: premier nœud (7 catégories) - NLP MATRIX - ARI: 0,63

nlp_matrix's Labels Confusion Matrix

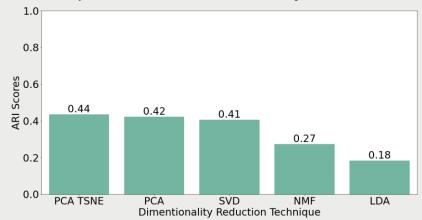




Catégorie: premier nœud (7 catégories) Computer Vision



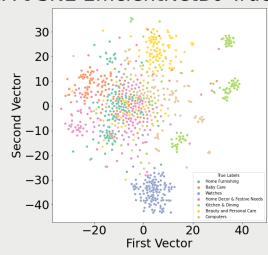
Best scores per Feature Dimentionality Reduction Technique



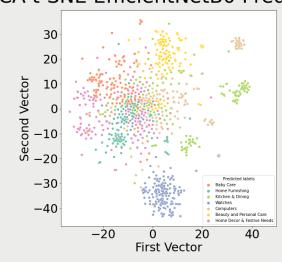


Catégorie: premier nœud (7 catégories) - EfficientNetB0 - ARI: 0,44

PCA t-SNE EfficientNetB0 True Labels



PCA t-SNE EfficientNetB0 Predictions





Catégorie: premier nœud (7 catégories) - NLP MATRIX - ARI: 0,43

EfficientNetB0's Labels Confusion Matrix

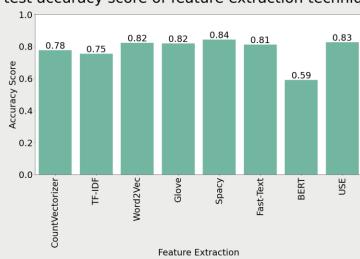




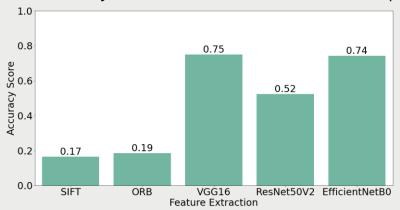


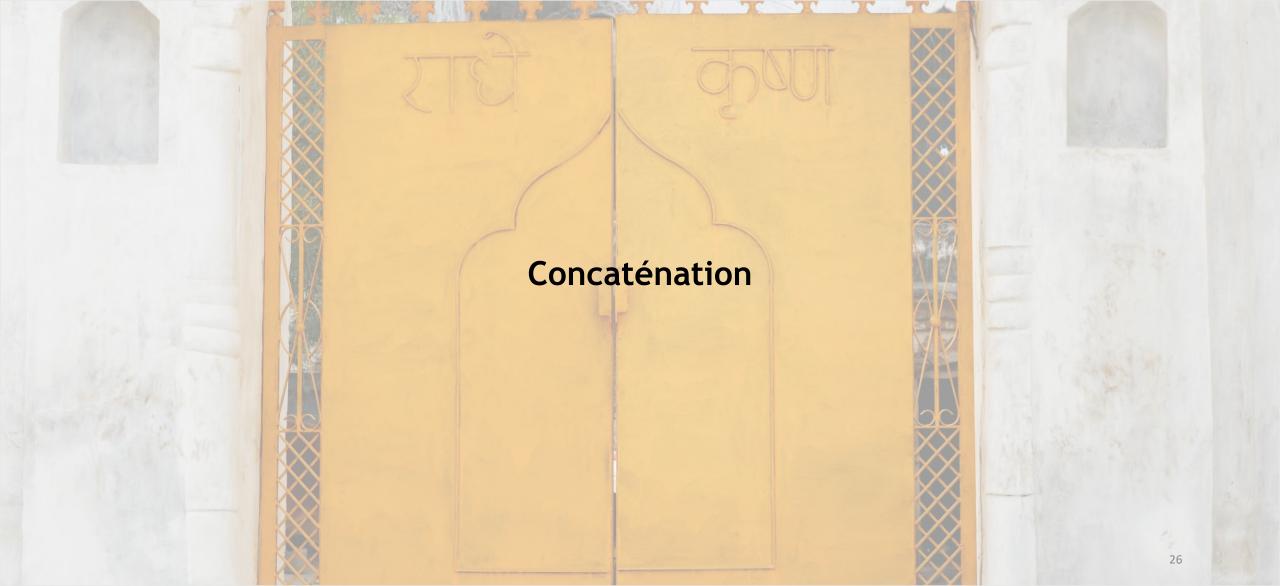
Catégorie: premier nœud (7 catégories) Supervisé

Mean test accuracy score of feature extraction techniques (CV:5)



Mean test accuracy score of feature extraction techniques (CV:5)







Catégorie: premier nœud (7 catégories) Supervisé

```
VotingClassifier

nlp_random_pipeline

cnn_random_pipeline

column_nlp: ColumnTransformer

nlp

cnn

CorpusEmbedder

CorpusEmbedder(embedder=<spacy.lang.en.English objec t at 0x00000243A0366C10>)

RandomForestClassifier

VotingClassifier

cnn_random_pipeline

cnn

column_cnn: ColumnTransformer

CNNExtractor

CNNExtractor

CNNExtractor(architecture='Efficient NetB0', pixel=224)

RandomForestClassifier

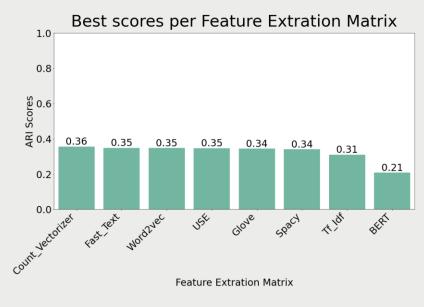
RandomForestClassifier
```

Accuracy: 0,86

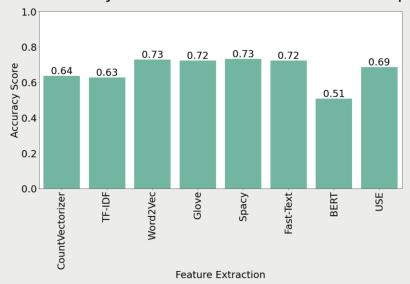




Catégorie : second nœud (62 catégories) - NLP

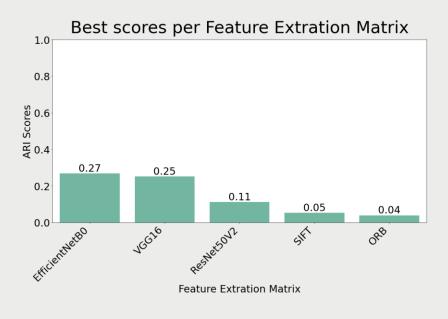


Mean test accuracy score of feature extraction techniques (CV:5)





Catégorie : second nœud (62 catégories) - Computer vision



Mean test accuracy score of feature extraction techniques (CV:5)

